

Aryan Sabounchi

1. ~~تعریف~~ $m \geq m_H(\epsilon, \delta)$, PAC learnability
و هر توزیع X روی S train set داریم:

$$P\{L_D(A(S_m)) < \epsilon_1\} \geq 1 - \delta$$

اگر $L_D(A(S_m)) < \epsilon_1$ باشد، بر اساس این که $\epsilon_1 \leq \epsilon_2$ (فرض مسئله)
~~باشد~~، $L_D(S_m) < \epsilon_2$ و به ازای هر $m \geq m_H(\epsilon_2, \delta)$

$$P\{L_D(A(S_m)) < \epsilon_2\} \geq 1 - \delta$$

چون $m = m_H(\epsilon_1, \delta)$ در قسمت اول صرفی کند، پس در قسمت دوم

هم صرفی کند یعنی $m_H(\epsilon_1, \delta) \geq m_H(\epsilon_2, \delta)$. برای $0 < \delta_1 < \delta_2 < 1$
 نیز دقیقاً به همین ترتیب است.

2.

(a) الگوریتم داده شده برای H singleton است که برای هر توزیع D

روی X اگر مجموعه آموزشی S با m عضو داشته باشد یا بیش از آن

در صورتی که $y_i = 1$ ، الگوریتم h_{x_i} را

برمی گرداند. در غیر این صورت h^- را برمی گرداند. با توجه به realizability condition

که تنها یک نقطه در X ممکن است وجود داشته باشد که بر حسب واقعی آن 1 باشد

وایم است که ~~یادگیری~~ الگوریتم بر روی train set همیشه درست عمل می کند.

(یعنی $L_S(h_S) = 0$ پس الگوریتم ERM است.)

(b) باید نهایت کنیم به ازای $\epsilon, \delta \in (0, 1)$

$$P(\{S_n \mid L_{(D, f)}(h_S) > \epsilon\}) < \delta$$

که (ا) توزیع دلخواه روی X ، تابع f تابع true labling است. یا توزیع به الگوریتم

اگر $f = h_-$ پس صورت خطای واقعی همیشه صفر است و شرط برقرار است

هم چنین اگر $f = h_{x_0}$ و $x_0 \in S$ ، در این حالت باز هم خطای حقیقی

صفر است و شرط برقرار است. در نتیجه باید حالتی را بررسی کنیم که $f = h_{x_0}$ اما

$x_0 \notin S$ و الگوریتم h_- را برگرداند یعنی $h_S = h_-$ پس

$$P(\{S_n \mid L_{(D, f)}(h_S) > \epsilon\}) \leq P(\{x_0 \notin S_n\})$$

چون اعضای S به صورت i.i.d انتخاب می شوند احتمال نبودن x_0 در S_n

برابر است با $1 - P(\{x_0\})$

$$\epsilon < L_{(D, f)}(h_-)$$

$$L_{(D, f)}(h_-) = P(\{h_-(x) \neq f(x)\}) = P(\{x_0\})$$

$$\Rightarrow \epsilon < P(\{x_0\}) \rightarrow 1 - P(\{x_0\}) < 1 - \epsilon$$

$$\rightarrow (1 - P(\{x_0\}))^m < (1 - \epsilon)^m \rightarrow$$

چون m عموماً داریم

نتیجه

$$P(\{S_n \mid L(y, h) > \epsilon\}) \leq P(\{x_0 \notin S_n\}) < (1-\epsilon)^m < e^{-\epsilon m}$$

$$\Rightarrow m \geq \frac{\ln(1/\delta)}{\epsilon} \quad (I)$$

پس برای (I)، خطای حقیقی یا احتمال 1-δ از ε کوچکتر است.

۱۳

طبق realizability assumption، یک h^* وجود دارد که دایره‌ای را

به L می‌گذراند که نقاط داخل دایره بر حسب 1 و نقاط خارج آن صفر است.
 ~~پس~~ L به L می‌گذراند که نقاط داخل دایره بر حسب 1 و نقاط خارج آن صفر است.
 ~~پس~~ L به L می‌گذراند که نقاط داخل دایره بر حسب 1 و نقاط خارج آن صفر است.

شعاع دایره را r^* می‌نامیم. اگر A را به گونه‌ای در نظر بگیریم که کوچک‌ترین دایره‌ای را
پوشاننده تمام نقاط مثبت و صفری در برگیرد، پس A به L می‌گذراند. ERM است.
شعاع این دایره را r_s می‌نامیم پس $r_s \leq r^*$

$$L_D(h_s) = P_{(x,y)}(h_s(x) \neq y) \quad (r_s \leq \|x\| \leq r^*)$$

$$P(\{x: r_s < \|x\| \leq r^*\}) = \epsilon, \quad E = \{x \in \mathbb{R}^2, r_s \leq \|x\| \leq r^*\}$$

احتمال اینکه یک نمونه از خطای حقیقی از E بزرگتر است یا احتمال این که هیچکدام
از training set عضو E نباشد یعنی $(1-\epsilon)^m$ پس

$$P(\{S_n \mid L_D(h) \mid > \epsilon\}) \leq P(\{S_n \mid S_n \cap E = \emptyset\})$$

$$\leq (1-\epsilon)^m \leq e^{-\epsilon m}$$

$$L \geq m \geq \frac{\ln(1/\delta)}{\epsilon}$$

و نهایت شد با اتمال $1-\delta$ ، خطای حقیقی از ϵ کوچکتر است.

□

4.

در نخست نهایت کی کیم فرضیات H مناسب است.

هر h می تواند با 3 حالت $(x_i, \bar{x}_i, \text{هیچ کدام})$ در Conjunction مشخص شود.

اشاره H بر این است:

$$|H| = 3^d + 1$$

چون فرضیات H مناسب است و به ازای $m \geq \frac{\log(|H|/\delta)}{\epsilon}$ ، برای هر توزیع دلخواه D

و تابع H true label PAC learnable است.

$$m \geq \frac{\log(\frac{3^d+1}{\delta})}{\epsilon} \geq \frac{\log(\frac{3^d}{\delta})}{\epsilon}$$

$$\text{Sample complexity } m_H(\epsilon, \delta) \leq \frac{\log(3^d/\delta)}{\epsilon} = \frac{d(\log 3 + \log(1/\delta))}{\epsilon}$$

3.46.

اگر مجموعه فرضیات H Agnostic PAC learnable باشد یعنی

$$\exists m_H: (0,1)^2 \rightarrow \mathbb{N}$$

یک الگوریتم A داشته باشیم که برای هر $\epsilon, \delta \in (0,1)$ و هر توزیع دلخواه D روی $X \times Y$

به ازای $m \geq m_H(\epsilon, \delta)$ نمونه از توزیع D یا احتمال $1-\delta$ تابع h را برگرداند طوری که

$$L_D(h) \leq \min_{h' \in H} L_D(h') + \epsilon$$

آنوقت اگر فرض کنیم شرط realizability برقرار باشد و تابع f true labeling

وجود داشته باشد، بنابراین یک توزیع دلخواه روی $X \times Y$ است طوری که $P_{Y|X}(y|x)$ با f معلوم شود. پس f برابری شود با توزیع روی X همیشه چون شرط realizability برقرار است $\min_{h' \in H} L_{(D,f)}(h') = 0$ پس با احتمال $1-\delta$

$$L_D(h) \leq 0 + \epsilon \rightarrow L_D(h) \leq \epsilon$$

7.
$$f_D(n) = \begin{cases} 1 & P[Y=1|X] \geq 1/2 \\ 0 & \text{o.w} \end{cases}$$

$$P[F_D(x) \neq y \mid X=x] = 1_{[\alpha_x \geq 1/2]} \cdot P[Y=0 \mid X=x] + 1_{[\alpha_x < 1/2]} \cdot P[Y=1 \mid X=x]$$

$$= 1_{[\alpha_x \geq 1/2]} \cdot (1 - \alpha_x) + 1_{[\alpha_x < 1/2]} \cdot \alpha_x = \min \{ \alpha_x, 1 - \alpha_x \}$$

$$\Rightarrow L_D(f_D) = \min \{ \alpha_x, 1 - \alpha_x \}$$

نرا یک تابع classifier دلخواه فرض می‌کنیم

$$L_D(y) = E_{(x,y) \sim D} [1_{y(x) \neq y}] = E_{x \sim D_x} \left[E_{y \sim D_{y|x}} [1_{y(x) \neq y}] \right]$$

$$= E_{x \sim D_x} [p(y(x) \neq y | x)]$$

$$p(y(x) \neq y | x) = p(y(x) = 0 | x) \cdot p(y = 1 | x) + \\ + p(y(x) = 1 | x) \cdot p(y = 0 | x)$$

$$\geq p(y(x) = 0 | x) \cdot \min\{\alpha_x, 1 - \alpha_x\} \\ + p(y(x) = 1 | x) \cdot \min\{\alpha_x, 1 - \alpha_x\}$$

$$\rightarrow E_{x \sim D_x} [p(y(x) \neq y | x)] \geq \min\{\alpha_x, 1 - \alpha_x\}$$

$$\rightarrow L_D(y) \geq L_D(f_D) \quad \blacksquare$$